

呼吸声分类的自适应差分去噪

Gaoyang Dong¹, Zhicheng Zhang², Ping Sun^{3*}, Minghui Zhang^{1*}

¹School of Information Engineering, Nanchang University, China

²School of Computer Science and Technology, Fudan University, China

³1st Affiliated Hospital of Nanchang University, China

donggyncu@email.ncu.edu.cn, zhangminghui@ncu.edu.cn

Abstract

呼吸声自动分类面临着背景噪声和现有系统去噪不足的现实挑战。我们提出了自适应差分去噪网络，该网络通过以下三点创新将噪声抑制和病理特征保存结合在一起：1)自适应频率滤波器，采用可学习的频谱掩模和软收缩，在保留诊断高频成分的同时消除噪声；2)差分降噪层，利用差分注意，通过增强样本比较降低噪声引起的变化；3)在没有干净标签的情况下，偏差去噪损失联合优化分类和鲁棒性。在ICBHI2017数据集上的实验表明，我们的方法达到了65.53%的分数，比之前的sota方法提高了1.99%。该代码可在<https://github.com/deegy666/ADD-RSC>中获得

Index Terms: respiratory sound classification, Adaptive Differential Denoising, differential attention, ICBHI 2017

1. 简介

自动呼吸声音分类 (ARSC) 已成为无创诊断肺部疾病(如哮喘、肺炎和慢性阻塞性肺疾病 (COPD)) [1]的关键工具。通过分析通过数字听诊器或可穿戴传感器捕获的听诊信号，ARSC系统旨在以临床水平的准确性对病理模式(例如，裂纹，喘息)进行分类。这种能力对于远程医疗应用和资源受限地区的早期筛查尤其有价值，这些地区获得专业肺科医生的机会有限[2]。

尽管具有临床前景，但目前的ARSC算法遇到了与数据限制相关的两个主要挑战：带注释的样本的稀缺性和普遍存在的环境噪声。最近，研究人员试图通过新的增强技术来缓解数据稀缺性。Siddhartha Gairola等人提出了空白区域剪切和基于串联的增强，以在扩大频谱多样性的同时保持病理语义[3]。jun - woo Kim等人开发了RepAug，用于从语音波形的预训练模型中提取增强特征[4]。jun - woo Kim等人也引入了对抗性微调技术作为数据增强方法[5]。同时，深度学习架构，如卷积神经网络 (CNN) [3, 6, 7]、音频谱图转换器 (AST) [4, 8, 9, 10]和层次令牌语义音频转换器 (HTS-AT) [11, 12]，通过捕获呼吸声学中的远程依赖关系，在特征提取方面显示出显著的效果。

然而，噪声污染问题仍然是呼吸声分类 (RSC) 的主要挑战。临床记录经常受到肢体运动引起的非静干干扰 (如摩擦伪影、心音)、环境噪声 (如对话干扰、听诊器-衣物接触噪声) 和传感器相关伪影的影响。传统的降噪方法，如谱减法[13]和维纳滤波技术[14]往往不能有效地抑制这些干扰，而不影响诊断的关键高频成分。常用的技术，如巴特沃斯带通滤波[15]和小波分解[16]，施加了严格的频谱约束：前者过度衰减超出标准呼吸范围 (100-2000 Hz) 的频率，不经意地丢弃了高频裂音 (> 2000 Hz) [17]等病理特征，而后者由于依赖固定基函数而导致瞬态特征丢失。

虽然深度学习推动了呼吸声音分析的进步，大多数现有的方法都遵循顺序去噪分类范式[18, 19, 20]，这有三个基本的局限性。首先，缺乏专门的呼吸声去噪数据集迫使研究人员使用非生物医学记录训练的通用音频去噪器。它造成了区域不匹配，损害了病理特征的保存。其次，针对一般音频任务对显式去噪模块进行了优化。然而，这些模块往往无意中消除了精细分类所必需的细微病理特征。第三，级联结构从根本上解耦了去噪和分类的目标，从而阻碍了噪声不变表示的联合优化。这种方法在处理非平稳生理噪声时效果不佳。这种噪音，例如心跳干扰，与目标呼吸事件具有相似的频谱-时间特征，使其去除特别具有挑战性。

为了弥补这一差距，本文介绍了一种隐式呼吸声去噪方法，该方法消除了传统的顺序去噪分类范式的需要，从而可以直接应用于RSC。总的来说，我们的贡献有三个方面：

- 据我们所知，这项研究是第一次探索专门针对呼吸声音的基于深度学习的去噪技术。
- 我们提出了一个自适应差分去噪 (ADD) 网络，其中包含一个自适应频率滤波器来抑制外源干扰，以及一个差分注意模块来细化细微的呼吸噪声。在此基础上，采用偏差感知损失函数对模型进行优化，通过隐式去噪提高分类性能。
- 我们的模型在ICBHI 2017基准上实现了最先进的性能，比以前的最佳方法高出1.99%。

2. 建议的方法

在本节中，我们介绍了RSC的自适应差分去噪框架。整个流水线如图1所示，它由三个关键组件组成：(1)自适应频率滤波器 (AFF)，(2)差分降噪层 (DDL) 和(3)损失函数。下面，我们将详细描述每个组件。

2.1. 预处理

在将音频信号输入模型之前，我们执行了一系列预处理步骤，以标准化输入格式并增强模型的鲁棒性。考虑到原始数据集中的呼吸录音是使用不同的设备收集的，采样率从4 kHz到44.1 kHz不等，所有音频信号都被重采样到16 kHz。

在ICBHI数据集中，呼吸周期的持续时间变化很大，从0.2秒到16.2秒不等。这种可变性给训练神经网络带来了挑战，因为神经网络需要固定大小的输入。我们确定8秒的长度可以产生最佳性能。为了确保一致性，使用循环填充延长较短的录音，而相应截断较长的录音。此外，应用幅度归一化来保持均匀的输入缩放。最后，我们将音频信号转换为Mel谱图 ($\mathbf{X}(t, f)$)，该谱图使用64个Mel滤波器和1024个样本的窗口大小进行计算。

*Corresponding author. And this research is supported by the National Natural Science Foundation of China under Grant No. 82260024




Figure 1: 提出的模型体系结构的总体说明。(a)表示自适应差分去噪框架，(b)表示具体的多头差别注意的细节（MHDA）机制。

2.2. 自适应频率滤波器

我们使用快速傅里叶变换（FFT）将 $\mathbf{X}(t, f)$ 从时频域转换到谱域，从而提取相应的频率表示。具体的变换公式如下：

$$\mathbf{X}(U, V) = \sum_{t=0}^{T-1} \sum_{f=0}^{F-1} \mathbf{X}(t, f) e^{-2\pi i(Ut + Vf)}. \quad (1)$$

在哪里 $\mathbf{X}(U, V)$ 表示调制频谱， U 和 V 分别对应沿时间和频谱维度的调制频率。 F 表示频谱图的频率维度的大小， T 表示频谱图的时间维度的大小。

随后，根据卷积定理，时域的卷积对应于频域的逐元乘法。我们应用了一种过滤机制，具有可学习的实例自适应掩码[21]。该机制用于信号的频率表示，并设计用于有效和自适应的呼吸声去噪。表示为：

$$\hat{X}(t, f) = \mathcal{F}^{-1}[S_{\alpha}(\mathcal{M}(\mathbf{X}(U, V))) \odot \mathbf{X}(U, V)], \quad (2)$$

其中 $\mathcal{M}(\cdot)$ 可学习实例自适应掩码。具体来说，它由可学习的线性层、Relu和另一个线性层组成。 $\mathcal{F}^{-1}(\cdot)$ 表示傅里叶反变换。 $S_{\alpha}(\cdot)$ 为软收缩，表示如下：

$$S_{\alpha}(x) = \text{sign}(x) \max\{|x| - \alpha, 0\} \quad (3)$$

其中 α 是控制稀疏度的调优参数。除了降噪之外，还可以提高稀疏性并处理L1归一化。

2.3. 差分降噪层

为了消除细微的噪音，同时保留呼吸声音的主要特征，我们引入了差分降噪层。与依赖显式噪声估计的传统去噪技术不同，我们的方法通过计算输入的多个增强视图之间的差分注意力来利用对比特征细化。该方法有效地抑制了噪声，同时保留了判别信号成分。

如图1(a)所示，DDL最初应用层归一化（LN）来稳定特征分布并减轻不同记录条件引起的变化。DDL的核心依赖于多头差分注意（MHDA）机制，该机制捕获输入信号的两个扰动表示之间的特征变化[22]。MHDA详细信息如图1(b)所示。具体来说，给定两个特征集，MHDA计算对比注意力分数如下：

$$[Q_1; Q_2] = \mathbf{XW}^Q, [K_1; K_2] = \mathbf{XW}^K, V = \mathbf{XW}^V \quad (4)$$

$$\mathbf{A} = \left(\sigma \left(\frac{Q_1 K_1^T}{\sqrt{d}} \right) - \lambda \cdot \sigma \left(\frac{Q_2 K_2^T}{\sqrt{d}} \right) \right) V \quad (5)$$

其中 $\mathbf{W}^Q, \mathbf{W}^K, \mathbf{W}^V$ 是可学习的投影矩阵。查询和键被分为 Q_1, Q_2 和 K_1, K_2 ，允许计算两个独立的注意图。如式5所示， σ 表示softmax函数， λ 是一个可学习的比例因子，控制第二个注意项的贡献。通过减去两个注意图，MHDA过滤掉噪声敏感的变化，同时保留稳定的、对分类至关重要的高置信度特征。

在注意力计算之后，随后的层归一化阶段进一步细化去噪的表示。最后，SwishGLU激活在保持平滑梯度流的同时引入非线性，从而保证了判别特征的保留。

通过利用差异注意机制，DDL抑制噪声敏感扰动，增强模型专注于稳定呼吸声音模式的能力。这种方法显著提高了对背景噪声和域移位的鲁棒性，使其对真实世界的呼吸声分类特别有效。

2.4. 损失函数

所提出的框架利用由两个主要成分组成的混合损失函数：

$$\mathcal{L} = \beta \mathcal{L}_{Bias\ Denoise} + (1 - \beta) \mathcal{L}_{CE} \quad (6)$$

其中 β 为超参数，控制去噪制导和分类精度之间的权衡。

我们使用标签平滑交叉熵对去噪过程进行正则化，表达式如下：

$$\mathcal{L}_{Bias\ Denoise} = - \sum_i \left[y_c(1 - \epsilon) + \frac{\epsilon}{C} \right] \log [\phi(Norm(p))] \quad (7)$$

其中 ϕ 是用于映射先前去噪特征的网络，具体来说我们使用 1×1 卷积层来表示它， y_c 是真实标签， C 是分类总数， p 是DDL网络之后衍生的特征。

与需要干净参考信号的光谱距离测量不同，我们的公式仅依赖于分类标签，这对于无法获得干净/噪声数据的实际部署至关重要。平滑操作将病理特征分布的先验医学知识注入到去噪过程中。此外，临床噪声经常与目标信号在频谱上重叠（例如，心音掩盖了细微的噼啪声）。标签平滑参数 ϵ 作为不确定性缓冲器，防止过度自信地去除可能包含诊断信息的模糊频段。

3. 实验

3.1. 实验设置

3.1.1. 数据集

本实验使用ICBHI 2017数据集[23]，这是最大的公开可用的呼吸声音语料库，用于评估。音频数据来自126名参与者。由于临床记录环境的复杂性，原始记录可能包含各种真实噪声干扰，如环境背景声（如病房设备嗡嗡声），生理干扰（如心音混叠），听诊器摩擦衣服产生的接触噪声。这些噪声与呼吸声在时频域的重叠特性大大增加了分类任务的难度。使用不同采样率（4 kHz、10 kHz、44.1 kHz）的各种设备记录数据集，单次记录的持续时间从10秒到90秒不等。噪声的异质性使得该数据集可以有效地验证模型在实际场景中的鲁棒性。根据官方方案，数据集被划分为训练集和测试集（60%-40%），同时保证患者身份不重叠，防止数据泄露。

3.1.2. 评估指标

为了确保我们评估的准确性和一致性，我们严格遵循ICBHI 2017挑战制定的官方评估方法。该方法全面和详细的，包括三个关键指标：敏感性（ S_e ），特异性（ S_p ）和Score。 S_e 、 S_p 、Score的定义如下：

$$S_e = \frac{\#of\ Correctly\ Recognised\ Abnormal\ Sounds}{\#of\ Total\ Abnormal\ Sounds} \quad (8)$$

$$S_p = \frac{\#of\ Correctly\ Recognized\ Normal\ Sounds}{\#of\ Total\ Normal\ Sounds} \quad (9)$$

$$Score = \frac{S_e + S_p}{2} \quad (10)$$

式中， S_e 表示在所有异常音中识别异常音的准确率， S_p 表示在所有实际正常音中识别正常音的准确率。 $Score$ 是异常和正常声音的平均值。特别地，该数据集中的异常声音包含Wheeze，Crackle和两者（Wheeze&Crackle）

3.1.3. 培训详情

在训练阶段，我们在Tesla V100 GPU上使用Pytorch 2.3.1框架进行了实验。我们使用Adam优化器，将权重衰减设置为0.1，学习率设置为5e-5，批大小设置为8，epoch设置为50。对于骨干网，我们使用了在AudioSet数据集上预训练的Resnet50和AST-Base模型。指定了实验超参数： β 为0.5， α 为0.02， ϵ 为0.2。

3.2. 实验结果

3.2.1. 与索塔方法的比较

我们将我们的方法与ICBHI 2017数据集上的各种SOTA方法进行了比较，如表1所示。表格分为两部分，上半部分是基于CNN的方法，下半部分是基于transformer的模型。

在上部，对于基于CNN的方法，我们提出的基于Resnet50的骨干网方法通过有效整合自适应差分去噪，达到58.97%的领先得分，超过了之前所有的CNN变体（例如，比CoTuning高出2.68%）。这验证了我们的框架与卷积运算的兼容性。

在表的下部，当在AST Transformer主干上实现时。我们的方法达到了65.53%的SOTA性能Score，优于所有现有的基于变压器的方法。具体来说，它比之前的最佳变压器方法（BTS [63.54%]）Score提高了1.99%，同时实

Table 1: 我们的方法与ICBHI数据集上最先进方法的比较。我们将其与之前的作品进行了比较（结果来自[24]）。

Model	$S_p(\%)$	$S_e(\%)$	Score(%)
LungRN+NL[25]	63.20	41.32	52.26
RespireNet [3]	72.30	40.10	56.20
Wang <i>et al.</i> [7] (Splice)	70.40	40.20	55.30
StochNorm[26]	78.86	36.40	57.63
CoTuning [26]	79.34	37.24	58.29
Chang <i>et al.</i> [27]	69.92	35.85	52.89
SCL [28]	75.95	39.15	57.55
Ours(Resnet50)	83.76	34.18	58.97
AFT on Mixed-500 [5]	80.72	42.86	61.79
AST Fine-tuning [9]	77.14	41.97	59.55
Patch-Mix CL[9]	81.66	43.07	62.37
M2D [29]	81.51	45.08	63.29
DAT [8]	77.11	42.50	59.81
SG-SCL [8]	79.87	43.55	61.71
RepAugment [4]	82.47	40.55	61.51
BTS [30]	81.40	45.67	63.54
MVST [31]	80.6	44.39	62.50
LungAdapter [32]	80.43	44.37	62.40
CycleGuardian [33]	82.06	44.47	63.26
Ours(AST)	85.13	45.94	65.53

现了最高的灵敏度（ S_e =45.94%，比BTS +0.27%）。特别是，我们的 S_p 达到85.13%，比RepAugment之前的记录（82.47%）建立了2.66%的差距，这表明在不影响检测灵敏度的情况下增强了特异性。

跨架构范式（CNN/Transformer）的一致性优势有力地验证了我们的自适应差分去噪机制与架构无关的本质。特别是，这两个指标的同时改进（传统上表现出权衡特征）表明，我们的方法有效地将呼吸声分析中的信号模式与噪声干扰分离开来。

3.2.2. 消融实验

Table 2: 本文提出的方法在ICBHI 2017数据集上的消融研究。主干是AST。

Model	$S_p(\%)$	$S_e(\%)$	Score(%)
w AFF	82.47	44.47	63.47
w DDL	83.73	44.03	63.88
w AFF+DDL	84.41	44.78	64.60
w AFF+ $\mathcal{L}_{BiasDenoise}$	83.76	44.62	64.19
w DDL+ $\mathcal{L}_{BiasDenoise}$	84.54	44.32	64.43
Ours	85.13	45.94	65.53

为了评估我们提出的方法中不同成分的贡献，我们使用AST作为主干对ICBHI 2017数据集进行了消融研究。结果如表2所示。

我们首先分别考察了AFF模块和DDL的影响。加入AFF后 S_p 提高到82.47%，得分达到63.47%，加入DDL后 S_p 提高到83.73%，得分达到63.88%。这表明两种成分都增强了模型性能，DDL在噪声抑制和特征细化方

面发挥了更重要的作用。

其次，我们分析了AFF和DDL相结合时模型的性能。同时使用AFF和DDL的模型达到 $S_p = 84.41\%$ ， $S_e = 44.78\%$ ，得分为64.60%，说明两个模块在提高分类性能方面是互补的。此外，我们探讨了积分偏置噪声损失 $\mathcal{L}_{BiasDenoise}$ 的影响。使用 $AFF + \mathcal{L}_{BiasDenoise}$ 和 $DDL + \mathcal{L}_{BiasDenoise}$ 的模型得分分别为64.19%和64.43%，表明偏差感知去噪进一步细化了特征表示，提高了模型的鲁棒性。

最后，我们的完整模型集成了AFF、DDL和 $\mathcal{L}_{BiasDenoise}$ ，得到了最好的性能， $S_p = 85.13\%$ ， $S_e = 45.94\%$ ，最终得分为65.53%。这些结果证实了我们方法中的每个组件在提高性能方面都起着至关重要的作用，并且它们的集成在ICBHI数据集上产生了最佳的分类精度。

4. 结论

在这项工作中，我们缓解了呼吸声去噪存在的空白。我们介绍了一种新颖的端到端隐式去噪方法，用于呼吸声音分类，专为缺乏专用去噪程序的数据集而设计。该方法首先通过AFF技术抑制大部分噪声，然后在DDL模块中利用差分注意力进行细粒度降噪过程。此外，我们引入了偏置去噪损失并实现了联合训练。进一步优化了模型性能。实验结果表明，我们的方法在CNN和Transformer架构上都具有优异的性能，表现出强大的鲁棒性，达到了65.53%的最先进精度，超过了所有现有的方法。在未来，我们将继续探索呼吸声事件检测任务的去噪技术。

5. 致谢

这项研究得到了国家自然科学基金的支持基金资助（82260024）感谢南昌大学第一附属医院和南昌大学影像与视觉表征实验室。

6. References

- [1] R. X. A. Pramono, S. Bowyer, and E. Rodriguez-Villegas, "Automatic adventitious respiratory sound analysis: A systematic review," *PloS one*, vol. 12, no. 5, p. e0177926, 2017.
- [2] A. Haleem, M. Javaid, R. P. Singh, and R. Suman, "Telemedicine for healthcare: Capabilities, features, barriers, and applications," *Sensors international*, vol. 2, p. 100117, 2021.
- [3] S. Gairola, F. Tom, N. Kwatra, and M. Jain, "Respirenet: A deep neural network for accurately detecting abnormal lung sounds in limited data setting," in *2021 43rd Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC)*. IEEE, 2021, pp. 527–530.
- [4] J.-W. Kim, M. Toikkanen, S. Bae, M. Kim, and H.-Y. Jung, "Repaugment: Input-agnostic representation-level augmentation for respiratory sound classification," *arXiv preprint arXiv:2405.02996*, 2024.
- [5] J.-W. Kim, C. Yoon, M. Toikkanen, S. Bae, and H.-Y. Jung, "Adversarial Fine-tuning using Generated Respiratory Sound to address class imbalance," *arXiv preprint arXiv:2311.06480*, 2023.
- [6] Y. Chang, Z. Ren, T. T. Nguyen, W. Nejdl, and B. W. Schuller, "Example-based explanations with adversarial attacks for respiratory sound analysis," *arXiv preprint arXiv:2203.16141*, 2022.
- [7] Z. Wang and Z. Wang, "A domain transfer based data augmentation method for automated respiratory classification," in *ICASSP 2022-2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2022, pp. 9017–9021.
- [8] J.-W. Kim, S. Bae, W.-Y. Cho, B. Lee, and H.-Y. Jung, "Stethoscope-guided Supervised Contrastive Learning for Cross-domain Adaptation on Respiratory Sound Classification," *arXiv preprint arXiv:2312.09603*, 2023.
- [9] S. Bae, J.-W. Kim, W.-Y. Cho, H. Baek, S. Son, B. Lee, C. Ha, K. Tae, S. Kim, and S.-Y. Yun, "Patch-Mix Contrastive Learning with Audio Spectrogram Transformer on Respiratory Sound Classification," *arXiv preprint arXiv:2305.14032*, 2023.
- [10] G. Dong, Y. Shen, J. Wang, M. Zhang, P. Sun, and M. Zhang, "Respiratory sounds classification by fusing the time-domain and 2d spectral features," *Biomedical Signal Processing and Control*, vol. 107, p. 107790, 2025.
- [11] W. Sun, F. Zhang, P. Sun, Q. Hu, J. Wang, and M. Zhang, "Respiratory Sound Classification Based on Swin Transformer," in *2023 8th International Conference on Signal and Image Processing (ICSIP)*. IEEE, 2023, pp. 511–515.
- [12] J. Wang, G. Dong, Y. Shen, M. Zhang, and P. Sun, "Lightweight hierarchical transformer combining patch-random and positional encoding for respiratory sound classification," in *2024 9th International Conference on Signal and Image Processing (ICSIP)*. IEEE, 2024, pp. 580–584.
- [13] N. Upadhyay and A. Karmakar, "Speech enhancement using spectral subtraction-type algorithms: A comparison and simulation study," *Procedia Computer Science*, vol. 54, pp. 574–584, 2015.
- [14] V. Ramasubramanian and D. Vijaywargi, "Speech enhancement based on hypothesized wiener filtering," in *INTERSPEECH*, 2008, pp. 167–170.
- [15] P. Podder, M. M. Hasan, M. R. Islam, and M. Sayeed, "Design and implementation of butterworth, chebyshev-i and elliptic filter for speech signal analysis," *arXiv preprint arXiv:2002.03130*, 2020.
- [16] M. Ali and P. Shemi, "An improved method of audio denoising based on wavelet transform," in *2015 international conference on Power, Instrumentation, Control and Computing (PICCC)*. IEEE, 2015, pp. 1–6.
- [17] A. G. Miller, H. L. Tan, B. J. Smith, A. T. Rotta, and J. H. Lee, "The physiological basis of high-frequency oscillatory ventilation and current evidence in adults and children: a narrative review," *Frontiers in physiology*, vol. 13, p. 813478, 2022.
- [18] J.-T. Tzeng, J.-L. Li, H.-Y. Chen, C.-H. Huang, C.-H. Chen, C.-Y. Fan, E. P.-C. Huang, and C.-C. Lee, "Improving robustness and clinical applicability of automatic respiratory sound classification using deep learning-based audio enhancement: Algorithm development and validation study," *arXiv preprint arXiv:2407.13895*, 2024.
- [19] S. Zhao and B. Ma, "Mossformer: Pushing the performance limit of monaural speech separation using gated single-head transformer with convolution-augmented joint self-attentions," in *ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2023, pp. 1–5.
- [20] Y. Luo and N. Mesgarani, "Conv-tasnet: Surpassing ideal time-frequency magnitude masking for speech separation," *IEEE/ACM transactions on audio, speech, and language processing*, vol. 27, no. 8, pp. 1256–1266, 2019.
- [21] Z. Huang, Z. Zhang, C. Lan, Z.-J. Zha, Y. Lu, and B. Guo, "Adaptive frequency filters as efficient global token mixers," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2023, pp. 6049–6059.
- [22] T. Ye, L. Dong, Y. Xia, Y. Sun, Y. Zhu, G. Huang, and F. Wei, "Differential transformer," *arXiv preprint arXiv:2410.05258*, 2024.
- [23] B. Rocha, D. Filos, L. Mendes, I. Vogiatzis, E. Perantoni, E. Kaimakamis, P. Natsiavas, A. Oliveira, C. Jácome, A. Marques *et al.*, "A respiratory sound database for the development of automated classification," in *Precision Medicine Powered by pHealth and Connected Health: ICBHI 2017, Thessaloniki, Greece, 18-21 November 2017*. Springer, 2018, pp. 33–37.
- [24] "Icbhi respiratory sound database: Audio classification state-of-the-art on papers with code," 2025, accessed: 2025-02-18. [Online]. Available: <https://paperswithcode.com/sota/audio-classification-on-icbhi-respiratory>

- [25] Y. Ma, X. Xu, Q. Yu, Y. Zhang, Y. Li, J. Zhao, and G. Wang, "Lungbrn: A smart digital stethoscope for detecting respiratory disease using bi-resnet deep learning algorithm," in *2019 IEEE Biomedical Circuits and Systems Conference (BioCAS)*. IEEE, 2019, pp. 1–4.
- [26] T. Nguyen and F. Pernkopf, "Lung sound classification using co-tuning and stochastic normalization," *IEEE Transactions on Biomedical Engineering*, vol. 69, no. 9, pp. 2872–2882, 2022.
- [27] Y. Chang, Z. Ren, T. T. Nguyen, W. Nejdl, and B. W. Schuller, "Example-based Explanations with Adversarial Attacks for Respiratory Sound Analysis," in *Proc. Interspeech 2022*, 2022, pp. 4003–4007.
- [28] I. Moummad and N. Farrugia, "Supervised contrastive learning for respiratory sound classification," *arXiv preprint arXiv:2210.16192*, 2022.
- [29] D. Niizumi, D. Takeuchi, Y. Ohishi, N. Harada, and K. Kashino, "Masked modeling duo: Towards a universal audio pre-training framework," *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 2024.
- [30] J.-W. Kim, M. Toikkanen, Y. Choi, S.-E. Moon, and H.-Y. Jung, "Bts: Bridging text and sound modalities for metadata-aided respiratory sound classification," in *Interspeech 2024*, 2024, pp. 1690–1694.
- [31] W. He, Y. Yan, J. Ren, R. Bai, and X. Jiang, "Multi-View Spectrogram Transformer for Respiratory Sound Classification," in *ICASSP 2024-2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2024, pp. 8626–8630.
- [32] L. Xiao, L. Fang, Y. Yang, and W. Tu, "Lungadapter: Efficient adapting audio spectrogram transformer for lung sound classification," in *Proc. Interspeech 2024*, 2024, pp. 4738–4742.
- [33] Y. Chu, Q. Wang, E. Zhou, L. Fu, Q. Liu, and G. Zheng, "Cycle-guardian: A framework for automatic respiratory sound classification based on improved deep clustering and contrastive learning," *arXiv preprint arXiv:2502.00734*, 2025.